


CLASIFICACIÓN DE ESTRÉS COGNITIVO EN ESTUDIANTES UNIVERSITARIOS MEDIANTE ANÁLISIS DE SEÑALES ECG Y TÉCNICAS DE MACHINE LEARNING BASADAS EN HRV

INTEGRANTES:

- **Noely Quiroz Rojas**
- **Anghely Alvarado Rosales**
- **Violeta Vilcapoma Torres**
- **Carla Fermin Jimenez**
- **Ximena Capa Ramirez**



INTRODUCCIÓN

SUNEDU: 1.37 millones de estudiantes matriculados en universidades licenciadas al 2022 [1].



De 1801 universitarios de 6 ciudades del Perú, 83% de estudiantes indican experimentar estrés académico durante el semestre [2].

Instrumentos subjetivos de evaluación: encuestas, escalas de autopercepción.



HRV, derivada del ECG, indicador robusto del balance simpático - parasimpático [3].



Paper	Objetivo	Procesamiento	Modelo ML	Resultado
Izzah et al. [4]	Clasificar estrés cognitivo mediante parámetros HRV derivados de ECG	ECG a 250 Hz, filtrado digital, detección de complejos QRS y extracción de variables HRV como SDNN, RMSSD y LF/HF	SVM, Random Forest, kNN y ANN	El modelo SVM logró diferenciar estados de relajación y estrés con 87.2% de precisión utilizando únicamente señales ECG. LF/HF y RMSSD fueron las variables más discriminativas
Dahal et al. [5]	Detectar estrés utilizando un conjunto reducido de variables HRV	ECG y extracción de variables HRV como HR, MEAN_RR, LF/HF y pNN25	Random Forest	El sistema alcanzó accuracies cercanas al 99.5% utilizando pocas variables HRV y manteniendo alta capacidad de clasificación
Al Hasan et al. [6]	Mejorar la clasificación de estrés mediante señales fisiológicas multimodales	ECG, filtrado digital y extracción HRV combinada con señales PPG y GSR	RF, SVM, kNN y Gradient Boosting	La combinación de señales fisiológicas permitió detectar estados de estrés con accuracies cercanas al 94%, superando el uso individual de señales
Salam et al. [7]	Clasificar estrés cognitivo mediante la integración de EEG y ECG	ECG, filtrado digital, ventanas de 60 s y extracción de variables HRV como SDNN y LF/HF	RF, SVM, Gradient Boosting y Redes Neuronales	La combinación EEG+ECG permitió identificar estrés cognitivo con accuracies cercanas al 95%. Las variables LF/HF y SDNN fueron las más relevantes

JUSTIFICACIÓN

Limitaciones

- Datasets privados o con acceso limitado
- Protocolos centrados en estrés social, laboral o multimodal
- Uso de señales adicionales como EEG, PPG y GSR
- Mayor complejidad en adquisición, sincronización y procesamiento de señales



Propuesta de proyecto

- Adquisición de señales ECG mediante BITalino
- Evaluación bajo condiciones de relajación y estrés cognitivo
- Procesamiento ECG mediante filtrado y detección de complejos QRS
- Extracción de parámetros HRV como RMSSD, SDNN y LF/HF
- Clasificación de estrés cognitivo mediante modelos de machine learning

Relevancia

- Sistema basado únicamente en ECG y HRV
- Menor complejidad computacional y de adquisición
- Pipeline reproducible para clasificación de estrés cognitivo
- Aplicación orientada a estudiantes universitarios

OBJETIVOS

OBJETIVO GENERAL:

Desarrollar un modelo de clasificación de estrés cognitivo en estudiantes universitarios basado en señales electrocardiográficas (ECG) y parámetros de variabilidad de la frecuencia cardiaca (HRV) utilizando técnicas de procesamiento de señales y Machine Learning.


OBJETIVOS ESPECÍFICOS:

- Adquirir las señales ECG mediante el dispositivo BITalino durante diferentes condiciones cognitivas asociadas a relajación y estrés.
- Procesar las señales ECG obtenidas mediante técnicas de filtrado y detección de complejos QRS.
- Extraer características fisiológicas relacionadas con HRV, como RMSSD, SDNN y relación LF/HF [3].
- Clasificar los niveles de estrés mediante Machine Learning.

METODOLOGÍA ABORDADA



**Adquisición
de señales**



**Procesamiento
de señales**





**Implementación
de Machine
Learning**



ADQUISICIÓN DE SEÑALES

- Las señales fisiológicas serán adquiridas utilizando el dispositivo BITalino y se utilizarán electrodos Ag/AgCl
- Registro realizado mediante software Open Signals



PROTOCOLO

En reposo

Resolución de
ejercicios aritmeticos bajo
presión de tiempo

Recuperación


PROCESAMIENTO DE SEÑALES

ETAPA DE PREPROCESAMIENTO

- Filtro Notch 60 Hz
- Filtro Pasa-Banda(5-35Hz)

EXTRACCIÓN DEL COMPLEJO QRS

- La señal preprocesada se eleva al cuadrado
- Filtro pasa-bajas 5Hz



PROCESAMIENTO DE SEÑALES

OBTENCIÓN DE INTERVALOS RR

1. Se identifica previamente la ventana donde se encuentra el complejo QRS.
2. Se selecciona una plantilla de 120 ms representativa de un latido típico.
3. La plantilla se desliza sobre la señal filtrada.
4. Se calcula la correlación cruzada en cada posición.
5. El punto con máxima correlación se define como el pico R.
6. El intervalo RR se obtiene midiendo el tiempo entre dos picos R consecutivos.

CÁLCULO DE PARÁMETROS HRV

SDNN	Desviación estándar de todos los intervalos RR	Variabilidad global de la frecuencia cardíaca
RMSSD	Raíz cuadrada de la media de las diferencias cuadráticas entre intervalos sucesivos	Actividad parasimpática asociada a recuperación y relajación
LF	Potencia en baja frecuencia	Ritmos lentos de regulación autonómica
HF	Potencia en alta frecuencia	Actividad parasimpática relacionada con la respiración

IMPLEMENTACIÓN DE MACHINE LEARNING

- Morfología del Latido → Extracción de Intervalo Q-T y Picos R-S para capturar la respuesta del miocardio al estrés agudo.
- Análisis de variabilidad en tiempo (SDNN, RMSSD) y frecuencia (Ratio LF/HF) para evaluar el balance autonómico

Clasificación:

Análisis diferenciado por sexo para optimizar los umbrales de detección del pulso y HR

Evaluación de SVM (Kernel RBF) y Random Forest por su alta estabilidad en señales fisiológicas ruidosas.

AVANCES DE PROCESAMIENTO



- **Filtro pasabandas**

```
low = 5.0 / nyquist
```

```
high = 35.0 / nyquist
```

```
b_band, a_band = butter(4, [low, high], btype='band')
```

```
filtered_band_signal = filtfilt(b_band, a_band, signal)
```





AVANCES DE PROCESAMIENTO

- **Filtro notch**

```
q = 30 #quality factor
```

```
b_notch,a_notch = iirnotch(60,q,fs)
```

```
filtered_notch_signal = filtfilt(b_notch,a_notch,filtered_band_signal)
```



AVANCES DE PROCESAMIENTO

- **Extracción del complejo QRS**

```
diff_signal = np.diff(filtered_notch_signal, prepend=filtered_notch_signal[0])
squared_signal = diff_signal ** 2
b_low5, a_low5 = butter(2, 5.0 / nyquist, btype='low')
lowpass_5hz_signal = filtfilt(b_low5, a_low5, squared_signal)
window_length = int(0.12 * fs)
integrated_signal = np.convolve(lowpass_5hz_signal, np.ones(window_length)/window_length, mode='same')
```

- **Obtención de intervalos RR**

```
min_distance = int(0.4 * fs)
peaks, _ = find_peaks(integrated_signal, distance=min_distance, height=np.mean(integrated_signal))
rr_interval_s = np.diff(peaks) / fs
rr_interval_ms = rr_interval_s * 1000
```

AVANCES DE PROCESAMIENTO

- **Cálculo de parámetros HRV**

```
sdnn = np.std(rr_interval_ms)
rmssd = np.sqrt(np.mean(np.diff(rr_interval_ms)**2))
```

```
frequencies,psd = welch(rr_resampled, fs=fs_resample,nperseg = 256)
```

```
lf_band = (frequencies>=0.04) & (frequencies<=0.15) #frecuencias bajas
```

```
hf_band = (frequencies>=0.15) & (frequencies<=0.40) # frecuencias altas
```


```
lf_power = np.trapz(psd[lf_band],frequencies[lf_band]) #energía debajo de la curva para lf
```

```
hf_power = np.trapz(psd[hf_band],frequencies[hf_band]) #energía debajo de la curva para hf
```

```
lf_hf_ratio = lf_power/hf_power if hf_power>0 else 0
```

AVANCES DE PROCESAMIENTO

- **Dataset WESAD (Wearable Stress and Affect Detection) - S2**



=====

--- PARÁMETROS HRV CALCULADOS (WESAD S2)

=====

SDNN : 103.11 ms

RMSSD : 84.40 ms

Relación LF/HF: 1.30

=====

BIBLIOGRAFÍA

- [1] EPG Universidad Continental, “Educación universitaria en el Perú: situación actual y perspectivas,” Ucontinental.edu.pe, Feb. 29, 2024. <https://blogposgrado.ucontinental.edu.pe/educacion-universitaria-peru-situacion-actual-perspectivas#:~:text=De%20los%20m%C3%A1s%20de%201%20'374%2C000%20estudiantes,en%20situaci%C3%B3n%20de%20pobreza%20o%20pobreza%20extrema>.
- [2] M. Cassaretto, P. Vilela, and L. Gamarra, “Estrés académico en universitarios peruanos: importancia de las conductas de salud, características sociodemográficas y académicas,” LIBERABIT. Revista Peruana de Psicología, vol. 27, no. 2, p. e482, Dec. 2021, doi: 10.24265/liberabit.2021.v27n2.07.
- [3] K. M. Dalmeida and G. L. Masala, “HRV Features as Viable Physiological Markers for Stress Detection Using Wearable Devices,” Sensors, vol. 21, no. 8, p. 2873, Apr. 2021, doi: 10.3390/s21082873.
- [4] N. Izzah, A. P. Sutarto, and M. Hariyadi, "Machine Learning Models for the Cognitive Load Detection Using Heart Rate Variability Signals," Jurnal Teknik Industri, vol. 24, no. 2, pp. 83–94, Dec. 2022, doi: 10.9744/jti.24.2.83-94.
- [5] K. Dahal, B. Bogue-Jimenez, and A. Doblas, “Global Stress Detection Framework Combining a Reduced Set of HRV Features and Random Forest Model,” Sensors, vol. 23, no. 11, p. 5220, May 2023, doi: 10.3390/s23115220.
- [6] MD. N. Al Hasan, N. S. Noman, M. H. Chowdhury, and A. Chowdhury, “Improving Multimodal Stress Detection Using MAUS Dataset with PPG, ECG and GSR Signal,” 2025 International Conference on Electrical, Computer and Communication Engineering (ECCE), pp. 1–5, Feb. 2025, doi: 10.1109/ecce64574.2025.11013834.

BIBLIOGRAFÍA

- [7] A. Salam, F. Alam, D. Shah, S. U. Rahman, S. Ali, and M. Tahir, "Improving cognitive stress classification via multimodal EEG and ECG fusion: gender differences in physiological response," *Scientific Reports*, vol. 16, no. 1, Feb. 2026, doi: 10.1038/s41598-026-38356-3.
- [8] R. Singh, V. Ranjan, A. Ganguly, and S. Halder, "Stress Classification Using Heart Rate Variability and Machine Learning Models," *Procedia Computer Science*, vol. 258, pp. 4248–4256, 2025, doi: 10.1016/j.procs.2025.04.674.
- [9] H. F. Posada-Quintero and J. B. Bolkhovsky, "Machine Learning models for the Identification of Cognitive Tasks using Autonomic Reactions from Heart Rate Variability and Electrodermal Activity," *Behavioral Sciences*, vol. 9, no. 4, p. 45, Apr. 2019, doi: 10.3390/bs9040045.
- [10] M. Quadrini et al., "Stress detection with encoding physiological signals and convolutional neural network," *Machine Learning*, vol. 113, no. 8, pp. 5655–5683, Mar. 2024, doi: 10.1007/s10994-023-06509-4.
- [11] J. He, K. Li, X. Liao, P. Zhang, and N. Jiang, "Real-Time Detection of Acute Cognitive Stress Using a Convolutional Neural Network From Electrocardiographic Signal," *IEEE Access*, vol. 7, pp. 42710–42717, 2019, doi: 10.1109/access.2019.2907076.
- [12] S. Gedam, S. Dutta, and R. Jha, "Analyzing mental stress in Indian students through advanced machine learning and wearable technologies," *Scientific Reports*, vol. 15, no. 1, Jul. 2025, doi: <https://doi.org/10.1038/s41598-025-06918-6>.
- [13] D. Zhai, X. Bao, X. Long, T. Ru, and G. Zhou, "Precise detection and localization of R-peaks from ECG signals," *Mathematical Biosciences and Engineering*, vol. 20, no. 11, pp. 19191–19208, 2023, doi: 10.3934/mbe.2023848.

GRACIAS

